

Тимур Бекмуратов

Senior AI / LLM Engineer

Алматы, Казахстан • timur.bekmuratov.ai@gmail.com • +7 707 919 22 11 • github.com/tbekmuratov

О СЕБЕ

AI/LLM Engineer с 4+ годами опыта построения production-grade систем на базе LLM. Специализация — RAG-архитектуры, агентные системы, fine-tuning. Знаю как бороться с галлюцинациями на практике: hybrid retrieval, citations, anti-hallucination проверки. Опыт в финтехе и enterprise. Изучаю prompt injection защиту и LLM observability.

ОПЫТ РАБОТЫ

Senior AI Engineer | Kaspi Lab

Январь 2023 — настоящее время

- Построил production RAG-систему для внутренней базы знаний банка (10K+ документов): LangChain, Qdrant hybrid retrieval (dense + BM25 + RRF), CrossEncoder reranking. Hit@5 = 0.87 на golden dataset.
- Разработал агентную систему на LangGraph для автоматизации поддержки операторов: 7-узловой граф, FastMCP tools, HITL через checkpoint, citation-grounded responses.
- Внедрил Langfuse для observability LLM-вызовов: трейсинг, мониторинг костов по командам, A/B-тестирование промптов.
- Eval-фреймворк на RAGAS (Faithfulness/Answer Relevancy/Context Precision/Recall) + кастомные метрики hallucination rate. CI/CD интеграция через Promptfoo.
- Защита от prompt injection: NeMo Guardrails, multi-layer sanitization (XML-теги, output validation, PII masking перед LLM).
- Снизил стоимость инференса на 38% через семантическое кэширование (GPTCache) + model routing (gpt-4o-mini для simple queries, gpt-4o для сложных).
- Менторство 2 junior LLM-инженеров: обучение RAG-паттернам, prompt engineering, eval-методологии.

ML Engineer | BTS Digital

Март 2021 — Декабрь 2022

- Разработка чат-бота поддержки клиентов на ранних LLM (GPT-3.5, потом GPT-4) + custom embeddings + FAISS.
- Fine-tuning DistilBERT для классификации намерений (intent classification) — accuracy 91% на казахско-русском датасете.
- Построение data pipeline для разметки диалогов (Label Studio), активное обучение.

Junior Data Scientist | Beeline KZ

Сентябрь 2019 — Февраль 2021

- Классические ML-задачи: churn prediction, propensity models на pandas + sklearn + XGBoost.
- EDA, feature engineering на телеком-данных.

ТЕХНИЧЕСКИЕ НАВЫКИ

Языки: Python (5 лет), SQL, Bash

LLM / Agents: LangChain, LangGraph (продвинутый), LlamaIndex, OpenAI API, Anthropic API, function calling, structured outputs

RAG: Qdrant (hybrid retrieval, payload indexing), Pinecone, Weaviate, chunking strategies, CrossEncoder reranking, RRF fusion

Fine-tuning: PEFT (LoRA, QLoRA), HuggingFace TRL (SFT, DPO), bitsandbytes 4-bit, datasets

LLM Observability: Langfuse, LangSmith, OpenTelemetry для LLM, кастомные трейсеры

Eval: RAGAS, Promptfoo, DeepEval, golden datasets, regression tests

ML core: PyTorch, HuggingFace Transformers, scikit-learn, sentence-transformers

Backend: FastAPI, async Python, SQLAlchemy 2.0, Pydantic

Infra: Docker, Kubernetes (basic), Redis, PostgreSQL, MongoDB

Безопасность LLM: NeMo Guardrails, prompt injection patterns (OWASP LLM Top 10), PII masking

ОБРАЗОВАНИЕ

Назарбаев Университет

MSc Computer Science • 2017 — 2019

КазНУ им. аль-Фараби

Бакалавр математики • 2013 — 2017

ДОКЛАДЫ И ПУБЛИКАЦИИ

- Доклад «RAG в проде: как мы боролись с галлюцинациями» — DataFest Almaty 2024.
- Статья на habr.com о hybrid retrieval — 15K+ просмотров.
- Open-source: контрибьютор LangChain (5 merged PRs в langchain-community).

ЯЗЫКИ

